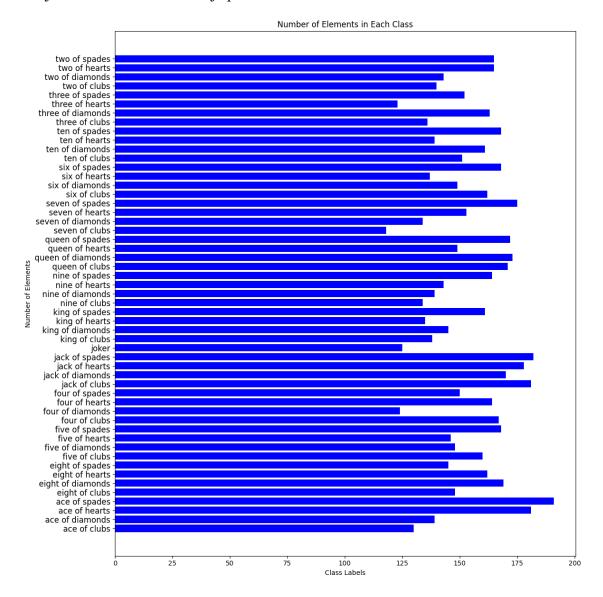
Projektni zadatak iz neuralnih mreža Klasifikacija karata – izveštaj

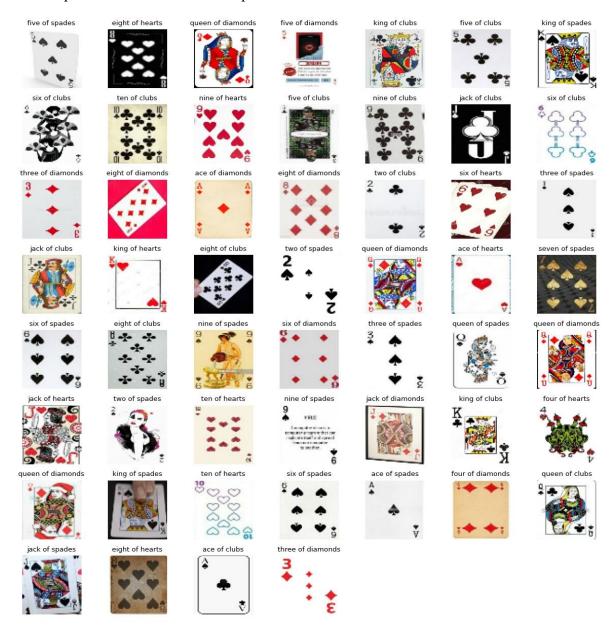
Dataset koji je korišćen je: https://www.kaggle.com/datasets/gpiosenka/cards-image-datasetclassification

Dataset se sastoji iz 53 klasa. Treba klasifikovati svaku od karata u posebnu klasu. Broj odbiraka za svaku klasu je prikazan na slici:



Podaci sa svaku klasu su relativno balansirani, ali u slučaju nebalansiranosti, primenili bismo class weights tehniku za razrešavanje.

Primerci podataka za svaku klasu su prikazani na slici:



U folderu je već bio izdeljen skup slika za trening, validaciju i testiranje, međutim, pošto skupovi za validaciju i testiranje nisu bili odgovarajućih veličina, prebacili smo sve podatke u jedan folder "Data" i nakon toga smo u kodu adekvatno podelili podatke za trening, validaciju i testiranje u odnosu 60-20-20. Podela podataka je bitna da bismo imali dovoljno veliki skup slika za validaciju i testiranje kako ne bi došlo do preobučavanja mreže na trening skupu.

Za predprocesiranje podataka smo koristili augmentaciju podataka tako što smo primenili rotaciju, uvećanje, i translaciju na nasumično odabranim podacima iz dataseta. Skalirali smo sliku sa 224x224x3 na 128x128x3.

<u>Kriterijumska funkcija</u> primenjena u projektu je SparseCategoricalCrossentropy(). Ovu kriterijumsku funkciju smo odabrali zato što je najčešće korišćena u konvolucionim neuralnim mrežama i optimizovana je za veći broj klasa, što One-Hot encoding radi vrlo neefikasno.

Izbor <u>funkcije aktivacije</u> neurona je "ReLU" zato što se omogućava da mreža uči višestruko brže od mreža koje koriste na primer tanh i sigmoid funkcije.

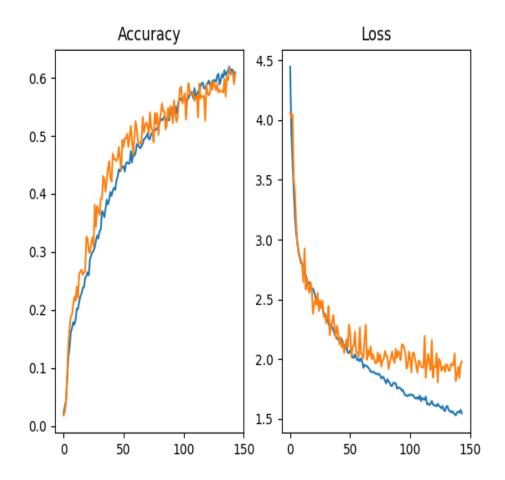
Izbor metode <u>optimizacije kriterijumske funkcije</u> je "Adam" kome je glavna prednost da dinamički prilagođava konstante obučavanja za svaki parametar mreže. Ovaj algoritam takodje doprinosi bržoj konvergenciji u odnosu na tradicionalne gradient descent algoritme.

U mreži postoji **5 konvolucionih slojeva** sa veličinom filtera 3x3, i sa brojem filtara 16, 32, 64, 128, 256 respektivno. Između svakog konvolucionog sloja, **postoji po jedan MaxPooling2D sloj**. Kako se dimenzije slike ne bi smanjivale prilikom nanošenja konvolucionog sloja, korišćen je padding. Nakon nanošenja svih konvolucionih slojeva iskorišćen je **dropout** radi sprečavanja od preobučavanja. Na samom kraju smo iskoristili flatten da ispravimo 3D izlaz u 1D i povezali ga na **fully connected sloj** sa 256 neurona koji koristi 12 regularizer, i taj sloj je povezan na izlaz mreze cija je aktivaciona funkcija softmax.

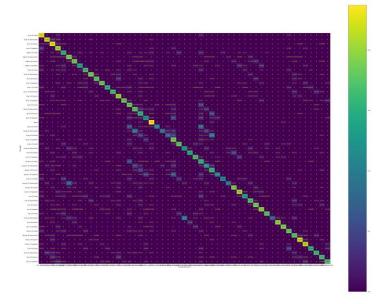
```
model = Sequential([
 data_augmentation,
 layers.Rescaling(1./255, input_shape=(128, 128, 3)),
layers.Conv2D( filters: 16, kernel_size: 3, padding='same', activation='relu'),
 layers.MaxPooling2D(),
 layers.Conv2D( filters: 32, kernel_size: 3, padding='same', activation='relu'),
 layers.MaxPooling2D(),
 layers.Conv2D( filters: 64, kernel_size: 3, padding='same', activation='relu'),
 layers.MaxPooling2D(),
 layers.Conv2D( filters: 128, kernel_size: 3, padding='same', activation='relu'),
 layers.MaxPooling2D(),
 layers.Conv2D( filters: 256, kernel_size: 3, padding='same', activation='relu'),
 layers.Dropout(0.2),
 layers.Flatten(),
 layers.Dense(units: 256, activation='relu', kernel_regularizer=l2(regularizer)),
 layers.Dense(num_classes, activation='softmax', kernel_regularizer=l2(regularizer))
```

<u>Preobučavanje neuralne mreže</u> nastaje kada su nekom skupu podataka za treniranje odlične, ali na skupu podataka za validaciju lose performanse. Tehnike zaštite od preobučavanja korišćene u ovoj mreži su dropout i 12 regularizacija pokazane na prethodnom primeru i early stopping koji prati validation loss funkciju sa strpljenjem 20.

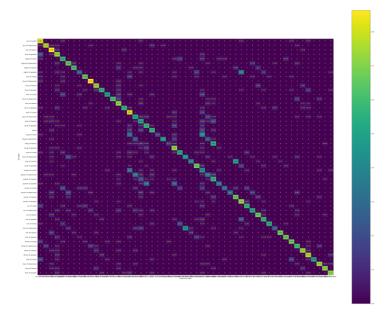
Grafik performanse:



Matrica konfuzije na trening skupu:



Matrica konfuzije na test skupu:



Prikaz nekoliko dobro klasifikovanih odbiraka:



Prikaz nekoliko <mark>lose</mark> klasifikovanih odbiraka:

